

LLD SDG



- **CÓDIGO:** LLD-SDG
- **TÍTULO:** LLD
- **FECHA:** 17/06/2026
- **VERSIÓN:** Primera

1.	INTRODUCCIÓN	3
2.	DESCRIPCIÓN DE LA APLICACIÓN	3
3.	ETIQUETADO (TAGGING)	3
4.	DIAGRAMAS DE ARQUITECTURA	4
5.	REDES	5
6.	COMPONENTES DE INFRAESTRUCTURA	5
6.1	SERVIDORES	5
6.2	ALMACENAMIENTO	5
6.3	BASE DE DATOS	6
6.4	INTEGRACIONES CON SERVICIOS TRANSVERSALES	6
7.	SEGURIDAD Y CUMPLIMIENTO	6
8.	DISPONIBILIDAD	6
9.	MONITORIZACIÓN Y ALERTAS	6
10.	BACKUPS Y RECUPERACIÓN	7
11.	MANTENIMIENTO Y ACTUALIZACIONES (PARCHEADO)	7
12.	DEVOPS (IAC)	7

1. INTRODUCCIÓN

El ejercicio plantea el diseño de la infraestructura cloud necesaria para desplegar un agente conversacional empresarial, partiendo de un diseño de alto nivel (HLD) que define los componentes lógicos de la solución pero no su implementación concreta sobre un proveedor cloud. El objetivo de este documento es traducir ese HLD a una arquitectura de bajo nivel (LLD) sobre Google Cloud Platform, especificando qué servicio gestionado de GCP cubre cada pieza, cómo se conectan entre sí de forma privada, y qué garantías de seguridad, resiliencia y coste ofrece el diseño resultante.

A nivel funcional, la aplicación resuelve el siguiente flujo: un usuario corporativo, ya autenticado en el directorio de la empresa, accede a una interfaz web (el frontend) desde la que mantiene una conversación en lenguaje natural. Cada mensaje del usuario viaja hacia un backend conversacional, que actúa como orquestador de la sesión: valida quién es el usuario, mantiene el contexto de la conversación, y delega la generación de la respuesta a un motor de insights. Ese motor es el que aplica la técnica de RAG (Retrieval-Augmented Generation): primero busca, entre los documentos y datos corporativos ya indexados, los fragmentos más relevantes para la pregunta del usuario, y después se los pasa junto con la pregunta a un modelo de lenguaje (LLM) para que genere una respuesta fundamentada en esa información, en lugar de inventarla.

La información corporativa que alimenta esa búsqueda no vive de forma nativa en la nube: procede de un sistema SAP on-premises, accesible mediante una API de acceso a datos. Para que el motor de insights pueda consultarla de forma rápida durante la conversación, existe un proceso independiente, ejecutado de forma periódica, que extrae esos datos de SAP, los transforma en representaciones vectoriales (embeddings) y los almacena en una base de datos preparada para búsqueda semántica. Este proceso de ingesta es asíncrono y desacoplado del flujo conversacional: el usuario nunca espera a que SAP responda en tiempo real, sino que consulta siempre datos ya preprocesados.

Por último, toda esta infraestructura necesita una capa transversal que no es visible para el usuario final pero que condiciona el resto de decisiones de diseño: una red privada que conecte los distintos componentes sin exponer ningún servicio a internet, una capa de autenticación que verifique la identidad de cada usuario antes de dejarle entrar, un sistema de gestión de secretos y credenciales, y mecanismos de despliegue automatizado (Infraestructura como Código y CI/CD) que permitan reproducir y evolucionar el entorno de forma controlada.

A grandes rasgos, los componentes lógicos del sistema son:


- Una interfaz de usuario (frontend), por la que entra y sale toda interacción humana.
- Un backend conversacional, que orquesta la sesión y el flujo de cada turno de conversación.
- Un motor de insights con capacidades de RAG, que combina recuperación de información y generación de lenguaje.
- Una base de datos de memoria conversacional, que conserva el historial de cada sesión.
- Un almacén vectorial, que conserva los datos corporativos indexados para su recuperación semántica.
- Una fuente de datos on-premises (SAP), accesible mediante una API de acceso a datos.
- Un proceso de ingesta periódico, que mantiene actualizado el almacén vectorial.
- Una capa de red, identidad y seguridad, que garantiza que toda comunicación es privada y autenticada.
- Una cadena de CI/CD e Infraestructura como Código, que automatiza el despliegue de todo lo anterior.

2. DESCRIPCIÓN DE LA APLICACIÓN


Nombre del Aplicativo	Agente Conversacional Empresarial (Conversational AI Assistant)
Funcionalidad principal	Asistente conversacional con capacidades de RAG (Retrieval-Augmented Generation) que responde preguntas de negocio basándose en información corporativa indexada desde SAP, combinando recuperación semántica de datos y generación de lenguaje natural mediante un LLM.
Usuarios objetivo	Empleados de la organización, autenticados mediante el directorio corporativo (Microsoft Entra ID), que necesitan consultar información de negocio almacenada en sistemas SAP de forma conversacional, sin acceso directo a SAP ni conocimientos técnicos de consulta de datos.

3. DIAGRAMAS DE ARQUITECTURA

Este apartado contiene la representación visual que muestra cómo está estructurada la solución tecnológica del proyecto detallando los componentes de red, computo, almacenamiento y entre otros componentes el gobierno híbrido que interactúan entre sí.



Por otro lado también tenemos los flujos de despliegue de infraestructura como código y del despliegue de los contenedores cloud run.



4. REDES

Topología general

La red se organiza en un patrón Hub-and-Spoke con tres VPCs independientes:

- **vpc-hub:** proyecto centralizado de conectividad. No despliega cargas de trabajo; concentra la conectividad híbrida (VPN hacia SAP on-premises y hacia Azure), el Network Connectivity Center (NCC) que interconecta todos los spokes, y los servicios de observabilidad y DNS agregados.
- **vpc-fe-shared:** spoke del Frontend, en modo Shared VPC (host project separado del service project), donde se despliega la interfaz de usuario.

- **vpc-be-shared**: spoke del Backend conversacional, también en modo Shared VPC, donde se despliegan el orquestador de sesión, el motor de insights (RAG) y el pipeline de ingesta de datos.

Conectividad entre spokes: NCC en lugar de VPC Peering

Se utiliza Network Connectivity Center en lugar de VPC Peering clásico porque el peering no es transitivo: si el Hub estuviera peered por separado con FE y con BE, el tráfico proveniente de SAP o Azure no llegaría a los spokes a través del Hub. NCC resuelve esto registrando cada túnel VPN y cada Shared VPC como un spoke, propagando rutas de forma transitiva entre todos ellos vía BGP.

Conectividad híbrida

Se despliegan dos túneles HA VPN independientes desde el Hub:

- Uno hacia el gateway on-premises de SAP, con BGP dinámico.
- Otro hacia Azure, que permite el acceso de Power BI y Active Directory a los recursos de GCP.

Ambos túneles se registran como spokes separados en NCC.

Aislamiento de red

Ningún componente de cómputo tiene IP pública. Cada Cloud Run del sistema usa Direct VPC Egress en modo "todo el tráfico", de forma que cualquier llamada saliente —incluidas las dirigidas a APIs de Google— se canaliza obligatoriamente a través de la VPC, sin depender de una regla de firewall que pudiera modificarse por error. La comunicación entre Frontend y Backend, y entre ambos spokes y las APIs de Google, se resuelve mediante Private Service Connect (sección de conectividad privada).

Subredes

Cada spoke dispone de dos subredes: una de carga de trabajo (donde residen los recursos de Cloud Run) y una proxy-only, obligatoria para el funcionamiento del Internal HTTPS Load Balancer que expone cada servicio dentro de su propia VPC.

5. COMPONENTES DE INFRAESTRUCTURA

Este apartado detalla los recursos de cómputo, sistemas operativos, almacenamiento, motores de bases de datos y servicios transversales asignados al proyecto, clasificados por sus respectivos entornos.

6. COMPUTO

El sistema se apoya íntegramente en Cloud Run, evitando la gestión de infraestructura propia (VMs o clústeres de Kubernetes), dado que el HLD no exige capacidades de orquestación

avanzada que justifiquen el coste operativo de GKE. Se despliegan cuatro servicios Cloud Run independientes, cada uno con su propio ciclo de vida de despliegue:

- **Cloud Run FE:** sirve la aplicación Angular del frontend. Ingress restringido a tráfico interno (Ingress = Internal), expuesto únicamente a través de un Internal HTTPS Load Balancer protegido por Identity-Aware Proxy.
- **Cloud Run CB-BE:** backend conversacional, responsable de orquestar la sesión del usuario, validar la autenticación y coordinar cada turno de la conversación.
- **Cloud Run CBE:** motor de insights, responsable de aplicar la lógica de RAG — recuperar los fragmentos relevantes del almacén vectorial y generar la respuesta mediante el LLM.
- **Cloud Run Jobs:** cómputo efímero usado en el pipeline de ingesta de datos (extracción desde SAP y generación de embeddings), orquestado por Cloud Scheduler y Cloud Workflows.

Todos los servicios Cloud Run usan Direct VPC Egress para que su tráfico saliente —incluido el dirigido a APIs de Google— transite siempre por la red privada de la organización.

7. DNS REGISTRO

La resolución de nombres se centraliza administrativamente en el proyecto Hub mediante Cloud DNS, usando zonas privadas con visibilidad restringida por VPC (split-horizon DNS). Esto permite que el equipo de plataforma gestione un único punto de configuración de DNS, aunque los recursos a los que apuntan esas zonas (los PSC Endpoints) sigan residiendo físicamente en el proyecto de red de cada spoke. Se definen zonas privadas para resolver las APIs de Google de cada spoke, una zona interna para la comunicación FE→BE, y zonas de forwarding hacia los dominios on-premises de SAP y de Azure Active Directory.

7.1 ALMACENAMIENTO

Cloud Storage se utiliza con dos propósitos diferenciados: por un lado, como repositorio de documentos subidos por los usuarios en el frontend, y por otro, como backend de estado remoto de Terraform (un bucket independiente y versionado por cada dominio: Hub, FE y BE), además de como destino de los backups programados de Firestore. Artifact Registry, desplegado en ambos spokes, actúa como repositorio privado de imágenes Docker, sustituyendo a Container Registry y siendo accesible únicamente vía PSC.

7.2 BASE DE DATOS

Firestore, en modo nativo y configuración multi-región, es la única base de datos del sistema, y cubre dos necesidades distintas mediante colecciones separadas: por un lado actúa como Tracker Store, almacenando el historial y metadata de cada conversación (**conversations/**); por otro, actúa como almacén vectorial para RAG (**embeddings/**), aprovechando su capacidad nativa de búsqueda vectorial (KNN) para evitar introducir un segundo motor de base de datos dedicado a este propósito.

7.3 SERVICIOS PAAS / IA

- **Secret Manager:** Servicio gestionado creado manualmente e importado al state de terraform y gestionado mediante pipelines en azure devops pipelines.
- **Google Cloud Backup y DR:** Automatización y gestión centralizada de las copias de seguridad consistentes con la aplicación y la recuperación rápida ante desastres de las cargas de trabajo IaaS, gestionado en terraform para realizar backups diarios para su posible restauración en caso de necesidad por parte del cliente.
- **Google Cloud Monitoring y Cloud Logging:** Servicio gestionado de observabilidad encargado de la ingesta masiva, agregación de logs basado en ciertos parámetros.
- **Vertex AI** es el servicio gestionado que provee tanto los modelos de generación (LLM) como los modelos de embeddings usados para vectorizar el contenido corporativo. Se consume siempre a través de Private Service Connect, nunca de forma pública. El pipeline de ingesta combina tres servicios PaaS de orquestación: Cloud Scheduler (disparador periódico), Cloud Workflows (orquestador de los pasos del pipeline, con reintentos declarativos) y Cloud Run Jobs (ejecución de la extracción y la generación de embeddings).

7.4 INTEGRACIONES CON SERVICIOS TRANSVERSALES

- La integración con sistemas externos a GCP se realiza a través de la capa de conectividad híbrida del Hub: la API de acceso a datos de SAP se consume mediante el túnel VPN hacia on-premises, y Power BI accede a los datos agregados de coste y uso (en BigQuery) mediante el túnel VPN hacia Azure. La autenticación de usuarios se federa con Microsoft Entra ID como proveedor de identidad externo (OIDC), integrado de forma nativa en Identity-Aware Proxy, sin necesidad de duplicar la gestión de identidades dentro de GCP. La gestión de secretos y credenciales (claves de API, credenciales de SAP) se centraliza en Secret Manager, uno por cada spoke.

8. SEGURIDAD Y CUMPLIMIENTO

Principio de diseño

La seguridad se construye sobre un principio de aislamiento por defecto: ningún recurso de cómputo tiene IP pública, y toda comunicación entre servicios —incluidas las llamadas a APIs gestionadas de Google— transita exclusivamente por la red privada de la organización. Esto se consigue combinando Direct VPC Egress (que obliga a que el tráfico saliente de Cloud Run pase por la VPC) con Private Service Connect (que resuelve ese tráfico a una IP interna en lugar de a una IP pública de Google).

Autenticación y control de acceso

El acceso de usuarios se protege mediante Identity-Aware Proxy, federado con Microsoft Entra ID como proveedor de identidad externo (OIDC), reutilizando el directorio corporativo ya existente sin duplicar la gestión de identidades en GCP. Ningún usuario llega a la aplicación sin haberse autenticado primero contra el IdP corporativo. A nivel de servicio a servicio, el acceso entre componentes se gestiona mediante cuentas de servicio con privilegio

mínimo, y el despliegue de infraestructura utiliza Workload Identity Federation en el pipeline de CI/CD, evitando el uso de claves de servicio en formato JSON en cualquier punto del proceso.

Cifrado

Todo el tráfico entre componentes viaja cifrado en tránsito (TLS), tanto en las conexiones a través de los Internal HTTPS Load Balancers como en los túneles VPN híbridos (IPsec). Los datos en reposo —Firestore, Cloud Storage, Secret Manager— se cifran por defecto con las claves gestionadas por Google (Google-managed encryption keys); el uso de claves gestionadas por el cliente (CMEK) mediante Cloud KMS se documenta como mejora recomendada para los datos más sensibles, sin ser parte del diseño base de esta fase.

Segmentación y reglas de firewall

Las reglas de firewall se aplican en dos niveles: jerárquico, mediante políticas globales a nivel de carpeta en Resource Manager, y específico, mediante reglas explícitas de ingress/egress en cada VPC de spoke. La regla general es "denegar todo por defecto" y permitir explícitamente solo los flujos documentados (tráfico desde el rango de IAP hacia los Load Balancers internos, y tráfico de egress de Cloud Run hacia los PSC Endpoints correspondientes).

Gestión de secretos

Las credenciales de servicios externos (API keys, credenciales de acceso a SAP) se almacenan en Secret Manager, con una instancia por cada spoke para mantener el aislamiento entre dominios. El acceso a los secretos se controla mediante IAM y se realiza siempre a través de Private Service Connect, nunca de forma pública.

Perímetro de seguridad de datos (recomendación futura)

VPC Service Controls no forma parte del diseño implementado en esta fase, pero se documenta como la evolución natural de seguridad recomendada, especialmente dado que el backend conversacional procesa datos provenientes de SAP. Un perímetro VPC-SC añadiría una capa adicional de control sobre qué proyectos pueden acceder a qué APIs de Google, more allá del aislamiento de red ya conseguido con PSC, a costa de una mayor complejidad operativa que no se ha considerado justificada para el alcance actual del ejercicio.

Auditoría

Todos los proyectos centralizan sus logs de auditoría en un sink de Cloud Logging agregado en el Hub, lo que permite trazabilidad cruzada de eventos de seguridad e infraestructura sin depender de revisar cada proyecto de forma independiente.

9. DISPONIBILIDAD

Este apartado describe los niveles de servicio técnicos, horarios de disponibilidad operativa y los procedimientos estándar de arranque y parada (Startup/Shutdown) para garantizar la integridad de los componentes que forman la solución.

10. MONITORIZACIÓN Y ALERTAS

Métricas Clave por Componente

Para asegurar el correcto funcionamiento de la solución, se evalúa de forma constante los siguientes indicadores clave:

Componente	Métrica Clave (KPI)	Umbral Alerta / Warning	Umbral Alerta / Crítica
Cloud Run FE	Latencia p95	> 1.5 s sostenido 5 min	> 3 s sostenido 5 min
Cloud Run FE	Tasa de errores 5xx	> 0.5% peticiones / 5 min	> 2% peticiones / 5 min
Cloud Run CB-BE	Latencia p95	> 2 s sostenido 5 min	> 4 s sostenido 5 min
Cloud Run CB-BE	Tasa de errores 5xx	> 0.5% peticiones / 5 min	> 2% peticiones / 5 min
Cloud Run CBE	Latencia p95 (incluye llamada a Vertex AI)	> 3 s sostenido 5 min	> 6 s sostenido 5 min
Cloud Run CBE	Tasa de errores 5xx	> 0.5% peticiones / 5 min	> 2% peticiones / 5 min
Vertex AI	Uso de cuota asignada	> 70% de la cuota	> 90% de la cuota
Vertex AI	Latencia de respuesta del modelo	> 4 s p95	> 8 s p95

Componente	Métrica Clave (KPI)	Umbral Alerta / Warning	Umbral Alerta / Crítica
Firestore	Latencia de <code>find_nearest()</code> (vector search)	> 300 ms p95	> 500 ms p95
Firestore	Latencia de lectura/escritura general	> 200 ms p95	> 500 ms p95
Pipeline de ingesta (Cloud Run Jobs)	Ejecuciones fallidas	1 fallo (con reintento pendiente)	Fallo tras agotar todos los reintentos
Pipeline de ingesta	Duración total del job	> 150% de la duración media histórica	> 250% de la duración media histórica
Conectividad híbrida (HA VPN SAP)	Estado del túnel	Latencia anómala / jitter elevado	Túnel en estado DOWN
Conectividad híbrida (HA VPN Azure)	Estado del túnel	Latencia anómala / jitter elevado	Túnel en estado DOWN
Internal HTTPS Load Balancer (FE / BE)	Tasa de errores del backend (5xx en el LB)	> 1% peticiones / 5 min	> 5% peticiones / 5 min
IAP	Tasa de autenticaciones rechazadas	> 5% de los intentos / 15 min	> 20% de los intentos / 15 min
Coste (Billing)	Gasto acumulado mensual vs. presupuesto	50–80% del presupuesto mensual	> 100% del presupuesto mensual
Coste (Vertex AI específico)	Gasto diario en inferencia/embeddings	> 120% del gasto diario medio	> 200% del gasto diario medio

11. BACKUPS Y RECUPERACIÓN

Backup de datos

Firestore, al ser el único almacén de datos del sistema (tanto para el tracker store de conversaciones como para el almacén vectorial de RAG), dispone de exportaciones programadas (Managed Export) hacia un bucket de Cloud Storage, con política de retención y versionado, permitiendo restaurar el estado de la base de datos ante un borrado accidental o una corrupción de datos. El propio Firestore en modo nativo ya replica los datos de forma síncrona entre múltiples zonas dentro de la región configurada, lo que protege frente al fallo de una zona individual sin intervención manual.

7.2 Backup de configuración e infraestructura

Toda la infraestructura está definida como código (Terraform), con su estado remoto versionado en buckets de Cloud Storage independientes por dominio (Hub, FE, BE). Esto significa que, ante la pérdida total de un proyecto, la infraestructura puede reconstruirse de forma reproducible a partir del código fuente, sin depender de un backup tradicional de configuración.

7.3 Alcance actual: una sola región

La capa de cómputo (Cloud Run FE, CB-BE, CBE) se despliega únicamente en una región. Sin embargo, dentro de las mismas VPCs de FE y BE (`vpc-fe-shared`, `vpc-be-shared`) se reserva una subred adicional en cada spoke (`gc-fe-02` con CIDR `10.103.1.0/24`, y `gc-be-02` con CIDR `10.104.1.0/24`), ubicada en una región secundaria y sin ningún recurso desplegado sobre ella. Esta subred no aloja Cloud Run, ILB ni PSC mientras el sistema opera en condiciones normales; existe únicamente para que el módulo de Terraform correspondiente pueda apuntar a ella de forma inmediata el día que se necesite.

7.4 Punto de mejora: proyecto de Disaster Recovery en una segunda región

Ante la caída completa de la región primaria, los datos permanecerían intactos y disponibles gracias a la multi-región nativa descrita en el punto anterior, pero no habría ningún servicio de cómputo capaz de atenderlos hasta ejecutar el despliegue en la subred reservada. El módulo de Terraform de cada Cloud Run está parametrizado para aceptar la región/subred de destino, de forma que el procedimiento de recuperación consiste en aplicar ese mismo módulo apuntando a `gc-fe-02` / `gc-be-02`, sin necesidad de diseñar la infraestructura desde cero en el momento del incidente. Esta aproximación evita el coste de mantener una segunda copia de Cloud Run corriendo de forma permanente, a cambio de un tiempo de recuperación (RTO) algo mayor que el de un esquema activo-pasivo con failover automático, que queda como evolución futura si el negocio llegara a requerir un RTO más agresivo.

Queda fuera del alcance de esta fase la resiliencia ante la caída completa del Hub project: una incidencia de ese tipo afectaría a la conectividad híbrida (túneles VPN hacia SAP y Azure), a NCC y al DNS centralizado, cuya reconstrucción excede el alcance de una subred reservada y requeriría un ejercicio de recuperación distinto, no cubierto en este diseño.

